




ארכיטקטורת סוכני בינה מלאכותית בשנת 2026

מיפוי טכנולוגי, ניתוח ביצועים ואסטרטגיות יישום בסביבות
פרודקשן


מרצה דר יורם סגל

תודה על הסיוע באיסוף החומרים

AGENT RUNTIME NETWORK

2026 היא נקודת המפנה הסוכנתית

סוכני AI עוברים ממנגנון עזר נקודתי לשכבת תפעול בתוך אפליקציות ארגוניות.



Runtime

הופך לשכבת תשתית

<5%

נקודת ייחוס לפי 2025

40%


מהאפליקציות
הארגוניות עד סוף
2026

תובנת מפתח: האתגר אינו רק לבחור מודל טוב יותר, אלא לבנות סביבו סביבת ריצה סוכנית אמינה.

מקור: Gartner, 2025 — תחזית אימוץ סוכנים ממוקדי משימה באפליקציות ארגוניות.

סוכן פרודקשן הוא מערכת, לא Prompt

PRODUCTION AGENT RUNTIME



Prompt טוב יכול להדגים יכולת. מערכת סוכנית יציבה דורשת שכבות תכנון, זיכרון, כלים ובקרה.

Planner מפרק משימה לצעדים ומחליט סדר פעולה.

Memory שומר היסטוריה, מצב עבודה ותובנות שימושיות.

Tools מחברים את הסוכן ל-APIs, קבצים ומערכות ארגוניות.

Observability מתעדת החלטות, עלויות, תקלות וסיכונים.

תובנת מפתח: ככל שהסוכן מקבל הרשאות רחבות יותר, שכבת הבקרה חשובה יותר מהמודל עצמו.

LangChain נותן התחלה; LangGraph נותן שליטה

ORCHESTRATION PATTERN SHIFT

LangChain: Linear Chain



Best fit: predictable pipelines, simple RAG, tool wrappers

LangGraph: Stateful Cyclic Graph



Best fit: long-running agents, branching decisions, durable execution

LangChain מתאים לזרימות ליניאריות, אינטגרציות מהירות ו-RAG בסיסי. כאשר הסוכן צריך לזכור מצב, לחזור אחורה או להמתין לאישור – נדרש גרף מצבי.

LangChain מקצר את הדרך מ-Prompt ליישום עובד, במיוחד בצינורות פעולה פשוטים.

LangGraph מוסיף תזמור stateful, הסתעפויות, לולאות וניהול רצף לאורך זמן.

בפרודקשן נדרשים persistence, fault tolerance, streaming, human-in-the-loop ו-observability.

תובנת מפתח: כאשר זרימת העבודה יכולה להסתעף, להיעצר או לחזור על עצמה – שרשרת אינה מספיקה; צריך מכונת מצבים סוכנית.

Ollama ו־Hugging Face מחזירים שליטה לתשתית

הבחירה בין הרצה מקומית לבין אקוסיסטם ענני אינה רק בחירת מודל; זו החלטה על פרטיות, Latency, עלות ותלות ספק.

תובנת מפתח

מודל פתוח מקבל ערך אמיתי רק כאשר סביבת ההרצה, מדיניות הנתונים ושכבת הכלים מתוכננות יחד.

1. Ollama להרצה מקומית

מתאים לפרטיות, ניסויים מהירים, עבודה Offline ובעלות גבוהה יותר על הנתונים.

2. Hugging Face לאקוסיסטם מודלים

מספק Hub, מודלים, כלים, Datasets, Spaces ויכולת אינטגרציה למסגרות סוכנים.

3. ההכרעה נעשית לפי עומס ורגולציה

יש למדוד Latency, VRAM, עלות טוקנים, אבטחת מידע ונפח שימוש לפני בחירה תשתיתית.

RUNTIME CONTROL MAP

Ollama

Local runtime, offline experiments, data ownership, private model serving.

Hugging Face

Model hub, datasets, spaces, inference providers, agent tooling.

Best When

Privacy, predictable workloads, low-latency local access, constrained data movement.

Best When

Fast model discovery, collaboration, managed inference, ecosystem integration.

LOCAL CONTROL

CLOUD ECOSYSTEM

Privacy

data boundary

Latency

runtime path

VRAM

capacity limit

Vendor Risk

lock-in level

Sources: Ollama documentation; Hugging Face smolagents and ecosystem documentation

Smolagents משנה את יחידת הפעולה

CODE ACTION RUNTIME

CodeAgent

receives task, context and tool schema

Python Action

loops · conditionals · function composition

Sandbox Boundary

Docker · E2B · Modal · Blaxel

Tool Execution

APIs · files · computation

Safe Output

validated · logged · returned

Visual labels intentionally remain English for LTR technical readability

ב־smolagents, ה־CodeAgent כותב פעולות כקוד Python, במקום להסתמך רק על קריאות כלים במבנה JSON.

קומפוזיציה: לולאות, תנאים וקינון פונקציות הופכים חלק טבעי מהפעולה.


יעילות: פעולה אחת בקוד יכולה להחליף רצף ארוך של קריאות כלים.

אבטחה: בפרודקשן, כל הרצת קוד חייבת לעבור דרך Sandbox קשיח.

תובנת מפתח: Code Agents חזקים במיוחד במשימות חישוביות, אך רק אם גבול ההרצה מבודד, מתועד ומוגבל הרשאות.

מקור: Hugging Face smolagents documentation ו־Agents Course על Code Agents.

פער ה-POC לפרודקשן הוא הסיכון השקט



Operational framing: dependencies · observability · debugging · maintainability

אב-טיפוס סוכני יכול להיראות מרשים בתוך ימים; מערכת ייצור נמדדת ביכולת לשחזר, לנטר, לתקן ולהגן לאורך זמן.

תלויות: מודלים, כלים, הרשאות ו-APIs משתנים מהר יותר ממערכות ארגוניות רגילות.

תצפית: בלי Trace מלא קשה לדעת מדוע הסוכן בחר פעולה, כמה היא עלתה ומה השתבש.


דיבוג: כש-Prompt, Memory וכלים משתנים יחד, תקלה קטנה הופכת למסלול חקירה ארוך.

תובנת מפתח: מהירות הדמו אינה מדד לאמינות מערכת ייצור; המדד האמיתי הוא יכולת שליטה תחת שינוי.

אקוסיסטם 2026 מתפצל לפי משימה

RAG	State	Types	Teams
knowledge-centric	workflow control	validated output	multi-agent roles

FRAMEWORK	BEST FIT	PRODUCTION STRENGTH	GOVERNANCE NEED
LangGraph	Stateful orchestration	High	Trace + checkpoints
LlamaIndex	RAG and data agents	High	Source control
PydanticAI	Structured outputs	High	Schema validation
DSPy	Prompt optimization	Medium	Evaluation sets
CrewAI	Role-based agent teams	Medium	Task boundaries
AutoGen / AG2	Conversational agents	Medium	Runtime limits
Mastra	TypeScript agent apps	Emerging	Platform maturity



Conceptual fit map based on architectural use cases, not a benchmark ranking.

בשנת 2026 אין Framework אחד שמנצח בכל תרחיש. הבחירה הנכונה מתחילה מהבעיה הארכיטקטונית, לא מהמותג.

תובנת מפתח

יש להתאים את הכלי למשימה: אחזור ידע, תזמור מצבי, פלט מובנה, אופטימיזציית Prompts או צוותי סוכנים.

תזמור מצבי

LangGraph

מידעו-RAG

LlamaIndex

צוותי סוכנים


CrewAI / AutoGen

פלט מובנה

PydanticAI

מרבֵי־סוכנים: שיחה חופשית מול שליטה דטרמיניסטית

MULTI-AGENT GOVERNANCE MAP



Qualitative architecture map: framework choice depends on risk, autonomy and auditability.

מערכות מרובות־סוכנים נעות על ציר עדין: יותר חופש שיחתי מגדיל גמישות וגילוי, אך מקשה על שחזור, אבטחה וממשל.


CrewAI מתאים לצוותים תפקידיים מוגדרים, דמו מהיר וחלוקת משימות ברורה.

AutoGen / AG2 מתאים למחקר, סימולציות ושיחות סוכנים גמישות סביב פתרון בעיות.

LangGraph מתאים כאשר צריך שליטה במצב, מעברים מוגדרים, אישור אנושי ושחזור.

תובנת מפתח: ככל שהסיכון העסקי גבוה יותר, כך כדאי להפחית שיחה חופשית ולהגביר תזמור דטרמיניסטי.

MCP ו-A2A יוצרים סטנדרט תקשורת



מערכות סוכניות לא יכולות להסתמך על אינטגרציות נקודתיות בלבד. הן צריכות שפה משותפת לחיבור כלים, משאבים וסוכנים אחרים.

MCP מחבר סוכן לכלים, משאבים ו-Prompts במבנה Client-Server המבוסס על JSON-RPC 2.0.

A2A מאפשר לסוכנים לגלות זה את זה, להחליף מידע ולהאציל משימות בצורה מאובטחת ובין-מערכתית.

ביחד הם מפרידים בין אינטגרציה אנכית לכלים לבין שיתוף פעולה אופקי בין סוכנים.

תובנת מפתח: ארגון שלא יתכנן סביב פרוטוקולים פתוחים עלול להיתקע בנעילת ספק ובאינטגרציות קשיחות.

מקורות: Model Context Protocol Specification; Linux Foundation Agent2Agent Protocol Project.

אבטחה סוכנית היא תחום חדש בפני עצמו

סוכן AI בפרודקשן אינו רק מודל שמחזיר תשובה; הוא רכיב תוכנה שמקבל מטרות, מפעיל כלים, נוגע בזהויות ומשאיר עקבות בזיכרון.

תובנת מפתח


לפי OWASP Top 10 for Agentic Applications, סיכוני אבטחה בסוכנים נובעים מהיכולת שלהם לתכנן ולפעול – לא רק לייצר טקסט.

Goal Hijacking: שינוי המטרה המקורית של הסוכן דרך קלט, זיכרון או כלי.

Tool Misuse: הפעלת כלי מורשה באופן שמייצר נזק, דליפה או פעולה לא צפויה.

Identity Abuse: שימוש לא מבוקר בזהות הסוכן, בהרשאות או באסימוני גישה.

Memory Poisoning: החדרת מידע שגוי לזיכרון שיכול להשפיע על החלטות עתידיות.



Observability הופכת לדרישת בסיס

סוכן בפרודקשן אינו יכול להיות “קופסה שחורה”. כל החלטה, כלי, עלות ותוצאה חייבים להיות מתועדים, נמדדים וניתנים לשחזור.

תובנת מפתח

בלי Trace אין אחריות; בלי Evaluation אין שיפור; בלי מדיניות אין פרודקשן בטוח.

1. Trace מלא


תיעוד קלט, החלטה, כלי, פלט, עלות, זמן ריצה ותוצאת פעולה.

2. Evaluations רציפות

בדיקות איכות, אמינות, Hallucination, מדיניות, Regression ועמידות מול שינויי מודל.

3. Human-in-the-loop

אישור אנושי בפעולות רגישות: שליחה, מחיקה, תשלום, שינוי הרשאות או פרסום.



TCO נקבע לפי נפח, פרטיות ו-VRAM

PRODUCTION AGENT TCO MODEL

TCO = Usage + Runtime + Governance + Operations

Evaluate monthly workload, data boundary, latency target and hardware capacity together.

Usage

tokens
calls
retries

Runtime

latency
cache
routing

Governance

privacy
audit
policy

Operations

VRAM
power
cooling

CONDITION	CLOUD API	LOCAL / SELF-HOSTED
Early pilot	Preferred	optional lab setup
High token volume	watch marginal cost	evaluate seriously
Strict data boundary	requires contracts	strong fit
Low latency target	depends on region	edge advantage
Small ops team	lower burden	needs GPU operations

Measure

real traces

Simulate

peak load

Revisit

every model cycle

עלות סוכן AI אינה רק מחיר טוקנים. בפרודקשן היא שילוב של נפח שימוש, זמני תגובה, דרישות פרטיות, חומרה, אנרגיה ותפעול שוטף.

תובנת מפתח

Cloud API עדיף להתחלה מהירה; הרצה מקומית מתחילה להשתלם כאשר נפח גבוה, רגולציה או Latency הופכים למגבלה עסקית.

Token Volume: מספר קריאות, אורך הקשר, Retrying ושיחות מרובות-שלבים מגדילים עלות מהר.

Latency: צורך בתגובה מיידית מכתוב בחירה בין API מרוחק, Edge, Cache או מודל מקומי.

Privacy: נתונים רגישים מעלים את ערך ההרצה המקומית, אך מוסיפים עלויות אבטחה ותפעול.

VRAM & Ops: GPU Hosting כולל זיכרון, חשמל, קירור, עדכונים, ניטור וזמינות.

אסטרטגיית יישום: Stack מודולרי ומבוקר

הדרך לפרודקשן ב־2026 אינה בחירת Framework יחיד, אלא בניית שכבות שליטה שמאפשרות ניסוי מהיר, מדידה, אבטחה והרחבה הדרגתית.



מקורות מרכזיים: LlamaIndex ו־Gartner Agentic AI Forecast; Model Context Protocol Specification; OWASP Top 10 for Agentic Applications; LangGraph, Hugging Face smolagents, Ollama .documentation